

Arquitetura Híbrida de IA para Análise Automatizada de Crédito PME na GCP: Solução Técnica Completa com ML Clássico, RAG, Governança, Segurança e FinOps

Elmer Dotti

Candidato – Desafio Técnico de AI Architecture / Analista de Crédito Híbrido

Maio de 2026

Resumo

Este artigo técnico apresenta uma solução fim a fim para automatizar a concessão de crédito a pequenas e médias empresas em uma instituição financeira digital *GCP First*, com volume de 10.000 solicitações por dia, dados estruturados em BigQuery e dados não estruturados em e-mails, contratos sociais em PDF e notícias de mercado. A proposta combina um motor determinístico de risco baseado em *gradient boosting* para estimar probabilidade de inadimplência, um agente de contexto GenAI com *retrieval-augmented generation* para produzir justificativas factuais, uma camada robusta de qualidade e contratos de dados, controles de privacidade por desidentificação de PII, perímetros de segurança com VPC Service Controls, orquestração multiagente A2A, explicabilidade por SHAP, governança inspirada no NIST AI RMF e uma memória de cálculo FinOps que demonstra a vantagem econômica de usar LLMs apenas nos casos cinzentos. O documento inclui diagramas, formulações matemáticas, ADR, exemplos reproduzíveis de entrada e saída, plano de implantação em produção e critérios operacionais para revisão humana. **Palavras-chave:** arquitetura de IA; análise de crédito; XGBoost; RAG; Vertex AI; BigQuery; Feature Store; SHAP; FinOps; LGPD; governança de IA.

1 Introdução

A automação de concessão de crédito em escala exige conciliar acurácia preditiva, explicabilidade, governança, privacidade, resiliência operacional e custo. O desafio técnico analisado descreve uma instituição financeira digital que recebe 10.000 pedidos de crédito por dia de PMEs, opera prioritariamente na Google Cloud Platform e precisa decidir automaticamente com justificativa, minimizando risco financeiro e operacional. A descrição da vaga, por sua vez, demanda visão arquitetural sênior para selecionar a ferramenta adequada para cada tipo de problema: ML clássico para previsão numérica, GenAI para linguagem e orquestração multiagente para composição de capacidades.

A decisão central desta solução é não usar um LLM como classificador principal de risco. A estimativa de probabilidade de inadimplência é tratada como problema tabular supervisionado, no qual modelos como XGBoost são reconhecidos por desempenho e escalabilidade em dados estruturados [1]. O LLM é usado onde agrega

maior valor: interpretação de contratos, e-mails, notícias e geração de pareceres fundamentados em evidências recuperadas por RAG, técnica originalmente proposta para combinar geração neural com documentos recuperados [3]. Essa separação reduz custo, aumenta controle e melhora auditabilidade.

2 Escopo, premissas e requisitos

A Tabela 1 sintetiza os requisitos técnicos derivados do desafio e as respostas arquiteturais adotadas.

3 Trabalhos relacionados e fundamentos

O XGBoost é uma implementação eficiente de *gradient tree boosting*, projetada com regularização e otimizações de sistema para tarefas supervisionadas em larga escala [1]. Em crédito, a modelagem de PD com árvores impulsionadas é adequada porque captura não linearidades em variáveis financeiras, comportamentais e cadastrais, ao mesmo tempo em que permite explicabilidade local por SHAP. O SHAP fundamenta-se em valores de Shapley da teoria dos jogos e fornece uma estrutura unificada para atribuição de importância de features em previsões individuais [2].

Para dados não estruturados, RAG reduz a dependência de conhecimento paramétrico do LLM ao condicionar a geração em passagens recuperadas de uma base documental controlada [3]. Em ambiente regulado, isso é essencial porque a justificativa precisa ser rastreável a evidências como balanços, histórico transacional, documentos societários e notícias verificadas. A governança segue princípios do NIST AI Risk Management Framework, que organiza sistemas de IA em torno de funções de governar, mapear, medir e gerenciar riscos [4]. A privacidade segue a exigência de revisão de decisões automatizadas prevista no art. 20 da LGPD para perfis de crédito [5].

4 Arquitetura proposta

A Figura 1 mostra a arquitetura de alto nível. A solução é dividida em seis planos: canais digitais, ingestão e qualidade, segurança e privacidade, motor numérico de risco, agente GenAI contextual e orquestração decisória.

Tabela 1: Rastreabilidade entre requisitos do desafio e decisões de solução.

Dimensão	Requisito	Resposta técnica proposta
Arquitetura e qualidade	Pipeline GCP fim a fim com validação de schema, data contracts, drift e fallback.	API Gateway, Pub/Sub, Dataflow, Dataform/Great Expectations, BigQuery, Vertex AI Feature Store e Model Monitoring.
Motor de risco	Score numérico e justificativa para XGBoost/Scikit-learn versus LLM.	XGBoost calibrado para PD, thresholds de decisão, SHAP para explicabilidade e LLM restrito a contexto textual.
GenAI contextual	Agente para e-mails, contratos e notícias.	Document AI/OCR, Sensitive Data Protection, embeddings, Vertex AI Vector Search, RAG e Gemini Flash/Pro.
Segurança e PII	Impedir exposição de PII ao GenAI e vazamento em logs.	DLP, tokenização, mascaramento, IAM mínimo, CMEK, VPC-SC, logs redigidos e auditoria.
Orquestração A2A	Interação entre agente de risco e agente textual; tratamento de falhas.	Orquestrador em Cloud Run usando LangGraph/Google ADK, com estados, timeouts, circuit breaker e revisão humana.
FinOps	Demonstrar custo de 100% Gemini Pro versus abordagem híbrida.	Memória de cálculo parametrizada por volume, caracteres/tokens, preços oficiais e taxa de zona cinzenta.
Governança	Prevenir alucinação e basear justificativas em fatos reais.	RAG com citações, evidências imutáveis, versionamento de features, trilhas de auditoria e revisão LGPD.




Figura 1: Arquitetura de referência C4 em alto nível para análise híbrida de crédito PME na GCP.

4.1 Ingestão, contratos e qualidade de dados

As solicitações são recebidas por Apigee ou API Gateway, autenticadas e publicadas em Pub/Sub. Dataflow realiza normalização, enriquecimento e separação entre dados estruturados e artefatos documentais. BigQuery armazena transações, balanços e cadastro; Cloud Storage mantém PDFs e anexos em zona *landing* criptografada. Antes de qualquer inferência, Dataform e Great Expectations validam contratos de dados: tipos, cardinalidade, chaves, faixas, integridade referencial, atualização temporal e regras de negócio.

A decisão de bloquear a automação quando uma variável crítica está corrompida evita *garbage in, garbage out*. Se uma feature transacional de alta importância estiver ausente, atrasada ou fora de distribuição, o pedido entra em revisão humana ou usa fallback conservador previamente aprovado pelo comitê de risco. O sistema nunca deve negar crédito exclusivamente por falha técnica sem evidência de risco; nesses casos, a resposta correta é

pendência operacional ou revisão manual.

4.2 Motor numérico de risco

O motor de risco estima a probabilidade de inadimplência, denotada por PD_i , para a empresa i . O modelo recomendado é XGBoost treinado em features estruturadas, com calibração por Platt scaling ou regressão isotônica.

$$\hat{p}_i = P(Y_i = 1 | \mathbf{x}_i) = \sigma(f_\theta(\mathbf{x}_i)) \quad (1)$$

onde $Y_i = 1$ indica inadimplência no horizonte de observação, $\mathbf{x}_i$ é o vetor de features da PME i , f_θ é a função aprendida pelo ensemble de árvores com parâmetros θ , $\sigma(z) = 1/(1 + e^{-z})$ é a função logística e $\hat{p}_i$ é a PD calibrada.

O score de crédito é convertido para escala operacional de 0 a 1000:

$$Score_i = 1000 \cdot (1 - \hat{p}_i) \quad (2)$$

onde $Score_i$ aumenta à medida que o risco estimado diminui. Essa escala facilita comunicação com negócio, políticas e mesa de crédito.

A decisão automática usa dois thresholds: T_A para aprovação e T_N para negação. Casos intermediários vão para revisão.

$$D_i = \begin{cases} \text{Aprovar,} & \hat{p}_i \leq T_A \wedge C_i \geq C_{min} \\ \text{Negar,} & \hat{p}_i \geq T_N \vee V_i = 1 \\ \text{Revisar,} & \text{caso contrário} \end{cases} \quad (3)$$

onde D_i é a decisão, C_i é a confiança consolidada do dossiê, C_{min} é a confiança mínima para decisão automática, V_i é indicador de veto material, T_A é o limite máximo de PD para aprovação e T_N é o limite mínimo de PD para negação.

4.3 Agente GenAI contextual com RAG

O agente textual não estima risco tabular; ele produz contexto e justificativa. Document AI extrai texto de contratos sociais e documentos. Sensitive Data Protection remove, mascara ou tokeniza PII antes de o conteúdo chegar ao LLM. A documentação oficial da Google define desidentificação como remoção de informações identificadoras, incluindo mascaramento, tokenização e criptografia/substituição [6]. Em seguida, embeddings transformam trechos em vetores e Vertex AI Vector Search recupera evidências relevantes.

Formalmente, para uma consulta q_i associada à solicitação i , o recuperador retorna:

$$R(q_i) = \text{topK}_{d_j \in \mathcal{D}} \text{sim}(E(q_i), E(d_j)) \quad (4)$$

onde $\mathcal{D}$ é o repositório documental autorizado, d_j é um trecho documental, $E(\cdot)$ é a função de embedding, $\text{sim}(\cdot)$ é a similaridade cosseno e K é o número de evidências recuperadas. O prompt do LLM recebe somente $R(q_i)$, metadados e score, nunca a base integral.

4.4 Orquestração A2A e protocolo de falhas

A Figura 2 detalha a colaboração entre os agentes. O orquestrador é implementado em Cloud Run, preferencialmente com LangGraph ou Google ADK, porque o fluxo exige estados explícitos, roteamento condicional, persistência de checkpoints, timeouts e tratamento assíncrono. A abordagem é orientada a eventos, com *correlation id* e idempotência para evitar decisões duplicadas.

A política de fallback é explícita. Falha de OCR em documento obrigatório gera revisão humana, não negação automática. Corrupção de dados transacionais críticos bloqueia a decisão automática. Divergência entre score baixo e notícia adversa relevante aciona revisão. Timeout no LLM permite decisão somente se o caso estiver fora da zona cinzenta e a política aprovar decisão sem contexto textual; caso contrário, abre pendência. A Figura 3 formaliza esse fluxo.

5 Segurança, privacidade e compliance

A solução aplica *security by design*. IAM usa privilégio mínimo por serviço: o endpoint de risco não lê documentos brutos; o agente RAG não acessa tabelas completas

de transações; o serviço de DLP grava somente saídas sanitizadas; e o orquestrador manipula identificadores pseudonimizados. BigQuery, Cloud Storage, Feature Store e Vector Search usam criptografia com Cloud KMS/CMEK quando requerido.

VPC Service Controls é usado como perímetro anti-exfiltração. A documentação da Google afirma que VPC-SC ajuda a mitigar risco de exfiltração em Vertex AI e pode proteger dados de treinamento, modelos, requisições de inferência, resultados batch e modelos Gemini [7]. Esse controle é particularmente importante porque e-mails, contratos e balanços contêm PII e sigilo bancário. Os logs são estruturados com redaction: CPFs, nomes, endereços, e-mails e números de conta não entram em logs de aplicação. Para auditoria, mantém-se apenas hash salgado, *correlation id*, versão de modelo, versão de feature set, decisões e evidências não sensíveis.

6 Governança, explicabilidade e prevenção de alucinação

A governança combina explicabilidade estatística e *grounding*. Para cada decisão, SHAP gera os principais fatores quantitativos. A explicação local de uma predição é dada por:

$$g(\mathbf{x}_i) = \phi_0 + \sum_{m=1}^M \phi_{im} \quad (5)$$

onde $g(\mathbf{x}_i)$ é a explicação aditiva da saída do modelo, ϕ_0 é o valor base esperado, M é o número de features e ϕ_{im} é a contribuição Shapley da feature m para o cliente i [2]. A justificativa textual do LLM deve citar evidências recuperadas e declarar incerteza quando o contexto for insuficiente.

A saída do LLM é validada por um *guardrail* com três regras: toda afirmação factual precisa apontar para uma evidência recuperada; o modelo não pode inventar dados cadastrais ou financeiros; e recomendações de decisão devem estar alinhadas ao score, às políticas e ao apetite de risco. Essa abordagem é consistente com o objetivo de RAG de condicionar geração a documentos externos recuperados [3].

7 FinOps e memória de cálculo

A arquitetura híbrida é economicamente superior porque XGBoost processa 100% dos pedidos com custo marginal muito baixo, enquanto Gemini é acionado apenas quando há texto relevante, zona cinzenta ou necessidade de justificativa ampliada. A página oficial de preços da Google lista modelos Gemini por volume de tokens ou caracteres e deve ser sempre validada no momento da contratação [8]. Para o exercício, usa-se premissa transparente: 10.000 pedidos/dia, 30 dias/mês, 24.000 caracteres de entrada e 4.000 caracteres de saída por caso textual, com preços legados localizados na página oficial para Gemini 1.5 Pro e Flash.

O custo mensal de processar todos os casos com Pro é:

$$Cost_{Pro} = N_d \cdot D \cdot \left(\frac{I}{1000} P_{Pro}^{in} + \frac{O}{1000} P_{Pro}^{out} \right) \quad (6)$$




Figura 2: Diagrama de sequência A2A entre agente de risco numérico, agente contextual, DLP, Feature Store e motor de políticas.

onde N_d é o número de pedidos por dia, D é o número de dias no mês, I é o volume médio de caracteres de entrada, O é o volume médio de caracteres de saída, P_{Pro}^{in} é o preço por mil caracteres de entrada do Gemini Pro e P_{Pro}^{out} é o preço por mil caracteres de saída.

O custo mensal híbrido é:

$$Cost_{Hybrid} = N_d \cdot D \cdot r_g \cdot \left(\frac{I}{1000} P_{Flash}^{in} + \frac{O}{1000} P_{Flash}^{out} \right) + Cost_{ML} \quad (7)$$

onde r_g é a proporção de casos cinzentos enviados ao LLM e $Cost_{ML}$ representa custo de Feature Store, endpoint XGBoost e orquestração, normalmente muito inferior ao custo de LLM em todos os pedidos para esse volume.




Figura 4: Comparação de custo mensal estimado entre processar 100% das solicitações com Gemini Pro e acionar Gemini Flash apenas nos casos cinzentos.

Tabela 2: Premissas FinOps parametrizadas.

Parâmetro	Valor usado no exemplo
Pedidos por dia	10.000
Dias por mês	30
Pedidos por mês	300.000
Entrada média por dossiê	24.000 caracteres
Saída média por parecer	4.000 caracteres
Zona cinzenta híbrida	5% a 30%

8 Exemplos de dados de entrada e saída

O contrato de API de entrada é JSON, versionado e validado por schema. Dados pessoais reais devem ser enviados apenas a serviços autorizados; nos exemplos, usa-se PII fictícia.

Listing 1: Exemplo de solicitação de crédito de entrada.

```
{
  "request_id": "cred-2026-000123",
  "company": {
    "cnpj": "12.345.678/0001-90",
    "legal_name": "Empresa Exemplo Ltda",
    "sector_cnae": "6201-5/01",
    "foundation_date": "2018-04-13"
  },
  "credit_request": {
    "amount_brl": 350000.00,
    "term_months": 24,
    "purpose": "capital_de_giro"
  },
  "documents": [
    { "type": "contrato_social", "gcs_uri": "gs://landing/cred-2026-000123/contrato.pdf" },
    { "type": "email", "gcs_uri": "gs://landing/cred-2026-000123/email.eml" }
  ]
}
```




Figura 3: Máquina de estados para decisão, revisão humana e fallback operacional.

A saída deve ser auditável, clara e adequada para negócio. Ela combina score, decisão, explicação SHAP, evidências RAG e canal de revisão.

Listing 2: Exemplo de saída operacional.

```
{
  "request_id": "cred-2026-000123",
  "decision": "REVIEW",
  "pd_calibrated": 0.083,
  "score": 917,
  "reason_codes": [
    "queda de margem operacional nos ultimos 2 trimestres",
    "aumento recente de concentracao em poucos clientes",
    "contrato social confirma poderes de representacao"
  ],
  "rag_evidence": [
    {
      "source": "balanco_2025_Q4",
      "claim": "margem operacional caiu de 14.2% para 9.1%"
    },
    {
      "source": "contrato_social",
      "claim": "administrador possui poderes para contratar credito"
    }
  ],
  "human_review_required": true,
  "lgpd_review_channel": "https://instituicao.example/revisao-decisao"
}
```

9 How-to de uso e execução

O fluxo operacional recomendado começa com provisionamento de infraestrutura por Terraform, implantação de pipelines e modelos, validação de contratos, carga inicial de features, indexação documental e ativação do endpoint de decisão. Em produção, cada solicitação deve seguir o contrato de API, receber *correlation id*, gerar trilha de

auditoria e produzir decisão ou fila de revisão.

9.1 Passo a passo de deploy

1. Criar projetos GCP segregados por ambiente: **dev**, **stg** e **prd**, com pastas e políticas organizacionais.
2. Habilitar APIs: BigQuery, Cloud Storage, Pub/Sub, Dataflow, Vertex AI, Document AI, Sensitive Data Protection, Cloud Run, Cloud KMS, Cloud Logging e Secret Manager.
3. Criar service accounts por componente, aplicando IAM mínimo e proibindo chaves estáticas.
4. Configurar buckets com CMEK, versionamento, retenção e políticas de acesso.
5. Criar datasets BigQuery para **raw**, **trusted**, **features**, **audit** e **monitoring**.
6. Implantar pipelines Dataflow e Dataform/Great Expectations para validar contratos de dados antes de materializar features.
7. Treinar XGBoost em Vertex AI Pipelines, registrar modelo no Model Registry e publicar endpoint com canary release.
8. Criar Feature Store com entidades **company**, **credit_request** e **financial_statement**, sempre com *point-in-time correctness*.
9. Configurar Document AI/OCR, Sensitive Data Protection e embeddings para indexar documentos sanitizados no Vertex AI Vector Search.
10. Implantar orquestrador em Cloud Run com variáveis

de ambiente para endpoints, thresholds, versão de políticas e feature views.

11. Configurar VPC Service Controls, Private Service Connect quando necessário, Cloud Armor, alertas de logs, SLOs e painéis de monitoramento.
12. Executar testes de integração com massas sintéticas, testes adversariais de prompt injection, testes de PII em logs e simulações de falha.

9.2 Exemplo mínimo de chamada

Listing 3: Exemplo de chamada do serviço de decisão.

```
curl -X POST https://credit-decision.example/v1/decisions \
-H "Authorization: Bearer_${TOKEN}" \
-H "Content-Type: application/json" \
-d @sample_credit_request.json
```

10 Monitoramento e operação

O monitoramento combina métricas de modelo, dados e negócio. Métricas de dados incluem completude, atraso, cardinalidade, distribuição e drift. Métricas de modelo incluem AUC, KS, Brier score, calibração, estabilidade de features e taxa de override humano. Métricas de GenAI incluem taxa de respostas sem evidência, custo por decisão, latência p95, taxa de fallback e ocorrências de PII em logs. Métricas de negócio incluem inadimplência observada, aprovação por faixa de risco, perda esperada, NPL, SLA e taxa de revisão LGPD.

A perda esperada por operação é:

$$EL_i = PD_i \cdot LGD_i \cdot EAD_i \quad (8)$$

onde EL_i é a perda esperada, PD_i é a probabilidade de inadimplência, LGD_i é a perda dado inadimplemento e EAD_i é a exposição no momento do default. A política deve aprovar crédito quando a margem ajustada a risco superar custo de capital, custo operacional e perda esperada.

11 ADR – Decisão arquitetural crítica

ADR-001: Usar arquitetura híbrida XGBoost + RAG/Gemini em vez de LLM único para decisão de crédito

Contexto. O problema combina dados tabulares massivos, documentos textuais e exigências regulatórias. Um LLM único para tudo teria custo elevado, baixa determinismo e maior dificuldade de validação estatística.

Decisão. Usar XGBoost calibrado como motor primário de PD para todos os pedidos e acionar RAG/Gemini somente para interpretação textual, justificativa e casos cinzentos.

Consequências positivas. A solução reduz custo, melhora auditabilidade, permite validação quantitativa clássica, preserva explicabilidade por SHAP e restringe o LLM a um domínio em que linguagem natural é necessária.

Trade-offs. A arquitetura fica mais composta e exige orquestração robusta, versionamento de features e gestão

de evidências. O custo operacional adicional é compensado por controle regulatório e economia de inferência.

12 Conclusão

A solução proposta atende integralmente ao desafio ao separar responsabilidades por natureza do problema: ML clássico para risco numérico, RAG/GenAI para interpretação textual fundamentada, DLP e VPC-SC para privacidade, Feature Store e contratos de dados para confiabilidade, SHAP e evidências para explicabilidade, revisão humana para incerteza e FinOps para viabilidade econômica. A arquitetura é implantável em produção na GCP, compatível com governança de IA e preparada para evolução incremental por canary release, monitoramento contínuo e auditoria.

Referências

- [1] T. Chen e C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” arXiv:1603.02754, 2016. Disponível em: <https://arxiv.org/abs/1603.02754>.
- [2] S. M. Lundberg e S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” arXiv:1705.07874, 2017. Disponível em: <https://arxiv.org/abs/1705.07874>.
- [3] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” arXiv:2005.11401, 2020. Disponível em: <https://arxiv.org/abs/2005.11401>.
- [4] National Institute of Standards and Technology, “AI Risk Management Framework,” 2023. Disponível em: <https://www.nist.gov/itl/ai-risk-management-framework>.
- [5] LGPD Brasil, “Artigo 20: Direito de revisão de decisões baseadas em tratamentos automatizados de dados pessoais.” Disponível em: https://lgpd-brasil.info/capitulo_03/artigo_20.
- [6] Google Cloud, “De-identifying sensitive data – Sensitive Data Protection.” Disponível em: <https://docs.cloud.google.com/sensitive-data-protection/docs/deidentify-sensitive-data>.
- [7] Google Cloud, “VPC Service Controls with Vertex AI.” Disponível em: <https://docs.cloud.google.com/vertex-ai/docs/general/vpc-service-controls>.
- [8] Google Cloud, “Agent Platform Pricing.” Disponível em: <https://cloud.google.com/gemini-enterprise-agent-platform/generative-ai/pricing>.
- [9] Google Cloud, “Using model monitoring.” Disponível em: <https://docs.cloud.google.com/vertex-ai/docs/model-monitoring/using-model-monitoring>.

- [10] Google Cloud, “Vertex AI Feature Store documentation.” Disponível em: <https://cloud.google.com/vertex-ai/docs/featurestore>.
- [11] Google Developers Blog, “Updated Gemini

models, reduced 1.5 Pro pricing, increased rate limits and more.” Disponível em: <https://developers.googleblog.com/en/updated-gemini-models-reduced-15-pro-pricing-increas>